



Análisis exploratorio y predictivo de la demanda de café a partir de series temporales

Autores:

Ignacio Tomás de Pedro Mermier - Luciano Adassus

Índice

1. Planteamiento de pregunta de investigación	3
2. Descripción de los datos	3
3. Descripción de los modelos	5
4. Pruebas sobre los modelos	12
5. Conclusiones	13

1. Planteamiento de pregunta de investigación

El objetivo principal de este análisis es responder a la siguiente pregunta:

¿En qué medida es posible predecir con precisión las ventas diarias de café utilizando únicamente información histórica, y cuál de los modelos propuestos (ARIMA, LSTM, Prophet, LightGBM) resulta más eficaz para anticipar la dinámica de la serie temporal?

Contexto y motivación:

La predicción de ventas en el sector de retail es una necesidad crítica para la planificación operativa, logística y financiera. En particular, las ventas de café pueden verse afectadas por patrones estacionales, tendencias a largo plazo, eventos puntuales (promociones, feriados) y posibles factores externos como el clima o cambios en el comportamiento del consumidor. Poder anticipar el volumen de ventas diarias permite ajustar la producción, optimizar inventarios y diseñar estrategias de marketing más efectivas.

Alcance:

El análisis se limita a las ventas diarias históricas de café contenidas en el dataset proporcionado. (`./coffee-dataset/index-1.csv`)

No se incorporan variables exógenas (clima, promociones, etc.), lo que establece un “piso” de performance basado sólo en patrones temporales propios de la serie.

El foco está tanto en la precisión de las predicciones como en la interpretabilidad y facilidad de uso de cada enfoque.

2. Descripción de los datos

Atributo	Tipo de Datos	Descripción
date	date	Fecha de la transacción (año-mes-día), útil para análisis agregados diarios.
datetime	datetime	Fecha y hora de la transacción de venta. Permite agrupar y ordenar temporalmente.
cash-type	string	Medio de pago utilizado (por ejemplo: ‘card’ para tarjeta, ‘cash’ para efectivo).
card	string	Identificador anónimo del medio de pago o del cliente (por ejemplo, tokenizado para preservar privacidad).
money	float	Importe total vendido en cada transacción, expresado en la moneda local.
coffe-name	string	Nombre comercial del tipo de café vendido (ejemplo: “Latte”, “Espresso”).

Utilidad y observaciones sobre cada atributo:

- **date:** es fundamental para la agregación diaria de ventas, que es la base de este análisis de series de tiempo.
- **datetime:** permite análisis a nivel de hora/minuto y, a futuro, puede usarse para estudiar patrones intradía, horarios pico, o planificar turnos de personal.
- **cash-type:** Indica si la compra fue realizada con tarjeta o efectivo. Si se dispone del dato, podría usarse para analizar tendencias en medios de pago, evaluar el impacto de promociones específicas para un método o detectar patrones asociados a cierto perfil de cliente.
- **card:** Es un identificador único anonimizado, útil para analizar la recurrencia de clientes, detectar hábitos de consumo, o incluso segmentar por frecuencia de compra.
- **money:** Es la variable objetivo para el análisis predictivo. Sumarizando por fecha, permite construir la serie diaria de ventas.
- **coffe-name:** Permite segmentar ventas por tipo de producto. En este análisis, la suma total de money por día es el foco, pero con este atributo es posible profundizar a nivel de preferencias de consumo, lanzamientos exitosos, o estacionalidad por producto.

Ventajas del esquema:

- Permite análisis univariados (ventas diarias totales) y multivariados (por tipo de producto, medio de pago, cliente).
- Facilita el cruce de información por fecha, tipo de producto o comportamiento de compra, habilitando estudios de patrones y segmentación avanzada.

Limitaciones:

- No se dispone de variables externas (promociones, clima, feriados), lo que acota la explicación de picos o caídas atípicas.
- El identificador de cliente está anonimizado; útil para estudios de recurrencia, pero limita la personalización.

Evolución diaria de las ventas a lo largo del año:




Figura 1. Se observa una serie temporal con variaciones pronunciadas, donde se destacan patrones de tendencia y picos recurrentes, sugiriendo la presencia de estacionalidad y posibles eventos atípicos.

3. Descripción de los modelos

El análisis se basó en una comparación de distintas familias de modelos para prever la evolución de las ventas diarias de café, considerando la serie histórica y los patrones visualizados en la exploración inicial.

1. Modelos clásicos de series temporales: ARIMA y SARIMA:

1.1. Justificación del modelo:

- Los modelos ARIMA (AutoRegressive Integrated Moving Average) y su extensión SARIMA (que incorpora estacionalidad) son ampliamente utilizados en predicción de series temporales, especialmente cuando se detectan componentes de tendencia y estacionalidad. Su fortaleza radica en la interpretación de componentes lineales y la descomposición en partes autoregresivas, integradas y de promedio móvil.

1.2. Preparación de datos:

- La serie diaria de ventas se transforma para asegurar la estacionaridad (eliminando tendencia y estacionalidad mediante diferenciación, si es necesario).
- Se analizan los gráficos de autocorrelación (ACF) y autocorrelación parcial (PACF) para definir los parámetros óptimos del modelo (p , d , q , y sus equivalentes estacionales).

1.3. Aportes del modelo:

- Muy bueno para series estacionarias y lineales.
- Su diagnóstico y tuning es transparente y basado en métodos estadísticos robustos.
- Como baseline, permite comparar contra modelos más complejos.

Figuras clave y su interpretación:




Figura 2. Al diferenciar la serie, se elimina la tendencia, lo que facilita el uso de modelos estacionarios como ARIMA y mejora la interpretación estadística.




Figura 3. Los gráficos muestran qué rezagos presentan correlación significativa. Esto orienta la elección de los parámetros autoregresivos y de media móvil del modelo ARIMA, sugiriendo el orden más adecuado para p y q .




Figura 4. La ausencia de correlación significativa en los residuos confirma que el modelo ARIMA seleccionado es adecuado, pues los errores son ruido blanco.




Figura 5. Los residuos están centrados en cero y su autocorrelación cae dentro de los límites de confianza, indicando que el modelo ajusta correctamente y no deja patrones sistemáticos sin explicar.




Figura 6. Se detectan algunos rezagos con autocorrelación significativa, señalando que este modelo alternativo no logra capturar completamente la dependencia temporal y es superado por otras configuraciones.




Figura 7. Se comparan diferentes parametrizaciones de ARIMA. El modelo elegido muestra un mejor ajuste visual a los valores reales, reduciendo la diferencia en picos y valles.




Figura 8. El modelo ARIMA reproduce correctamente la dinámica general de la serie, aunque puede subestimar algunos picos excepcionales.




Figura 9. El pronóstico realizado sobre datos no vistos mantiene la tendencia y la estacionalidad, lo que respalda la capacidad predictiva del modelo fuera del set de entrenamiento.




Figura 10. El modelo SARIMA logra un buen ajuste durante el periodo de entrenamiento, capturando tanto la tendencia como los ciclos estacionales de la serie.




Figura 11. La comparación muestra una superposición muy cercana entre la serie real y la predicha, lo que valida la calidad del ajuste alcanzado.




Figura 12. El modelo automático SARIMA, configurado con auto arima, extiende el pronóstico y mantiene un comportamiento coherente con la dinámica histórica.

2. Modelos de Machine Learning: LSTM

2.1. Justificación del modelo:

- Las redes neuronales LSTM (Long Short-Term Memory) son una variante de las redes recurrentes, capaces de capturar dependencias de largo plazo y patrones no lineales. Son ideales cuando la relación entre el pasado y el futuro de la serie es compleja, o cuando hay efectos “memoria” más allá del rezago inmediato.

2.2. Preparación de datos:

- Se normalizan los valores para facilitar el aprendizaje de la red.
- Se generan secuencias de ventas para que la LSTM aprenda los patrones temporales.
- Se divide el dataset en ventanas de entrada (look-back) y salida (predicción futura).

2.3. Aportes del modelo:

- Capaz de capturar relaciones no lineales y patrones complejos.
- Puede aprender de ventanas de tiempo largas.
- Menos interpretable, y requiere más datos y ajuste fino.

Figuras clave y su interpretación:




Figura 13. Se observa que el modelo logra reproducir de forma bastante fiel la tendencia global de las ventas y capta la estructura general de la estacionalidad, adaptándose a los aumentos y disminuciones a lo largo del tiempo.

3. Modelos de tendencia y estacionalidad: Prophet

3.1. Justificación del modelo:

- Prophet, desarrollado por Facebook, está diseñado para captar tendencias y estacionalidades de manera automática, incluso en presencia de outliers o cambios abruptos. Es especialmente útil cuando hay feriados, eventos especiales o patrones estacionales no triviales.

3.2. Preparación de datos:

- Se ajusta la serie en formato compatible con Prophet (dos columnas: fecha y valor).
- El modelo descompone la serie en tendencia, estacionalidad anual, semanal y efectos especiales.
- Permite incorporar feriados (no usados en este caso por falta de datos exógenos).

3.3. Aportes del modelo:

- Ajuste automático y robusto a cambios de patrón.
- Fácil de usar y de interpretar sus componentes.
- Flexible para eventos especiales.

Figuras clave y su interpretación:




Figura 14. El modelo predice bien los periodos de mayor demanda y ofrece intervalos de confianza útiles para anticipar la variabilidad futura. Aunque suaviza algunos picos extremos, brinda resultados consistentes y fácilmente interpretables, siendo ideal para prever comportamientos regulares a lo largo del tiempo.

4. Modelos de suavizamiento: EWMA y SMA

4.1. Justificación del modelo:

- El suavizamiento exponencial (EWMA) y la media móvil simple (SMA) ayudan a destacar la tendencia subyacente y a reducir el ruido, siendo un punto de partida visual y analítico para detectar cambios de nivel o régimen.

4.2. Preparación de datos:

- Se calculan promedios móviles sobre la serie diaria.
- Se grafican junto a la serie original.

4.3. Aportes del modelo:

- Muy útil para exploración inicial y para servir como baseline simple de predicción.
- Poco efectivo para capturar estacionalidad o shocks.

Figuras clave y su interpretación:




Figura 15. El suavizamiento exponencial y la media móvil resaltan la tendencia general de la serie, eliminando parte del ruido y facilitando la identificación de cambios de nivel.

5. Descomposición de la serie: Hodrick-Prescott y estacionalidad

5.1. Justificación del modelo:

- La descomposición ayuda a identificar y separar la tendencia de largo plazo, la estacionalidad y el componente aleatorio, fundamentando la elección de modelos y parámetros.

5.2. Preparación de datos:

- Se aplica el filtro de Hodrick-Prescott y técnicas de descomposición clásica.
- Se estudian períodos específicos con fuerte estacionalidad.

5.3. Aportes del modelo:

- Permite separar tendencia y estacionalidad: Facilita identificar cómo evoluciona la serie a largo plazo y qué patrones repetitivos existen.
- Ayuda a decidir si se necesitan modelos que capturen ciclos (como SARIMA o Prophet).
- Muestra cuándo ocurren picos o caídas, apoyando la interpretación y la toma de decisiones.

Figuras clave y su interpretación:




Figura 16. La descomposición permite distinguir la tendencia de largo plazo respecto al ciclo de corto plazo, confirmando que existen periodos de crecimiento y caída a lo largo del año.




Figura 17. Se identifican aumentos claros y repetidos en las ventas durante los meses de octubre a diciembre, lo que confirma una fuerte estacionalidad anual en la demanda.




Figura 18. Descomposición estacional de ventas diarias (Oct-Dic 2024): La serie se divide en componentes: tendencia, estacionalidad semanal y residuo. Se evidencia que gran parte de la variabilidad es explicada por estos patrones regulares.

4. Pruebas sobre los modelos

1. División de datos (train-test):

- Se reservó una parte de la serie temporal para testear los modelos fuera del período de entrenamiento, evaluando así la capacidad de generalización y evitando el sobreajuste.

2. Métricas de evaluación:

- Se emplearon métricas estándar para comparar el desempeño de los modelos:
 - MAE (Mean Absolute Error)
 - MAPE (Mean Absolute Percentage Error)

- R^2 (Coeficiente de determinación)
- MSE (Mean Squared Error)
- Se consideró como mejor modelo aquel que presenta menor MAE/MAPE/MSE y mayor R^2 .

3. Validación visual:

- Se graficaron los valores predichos por cada modelo contra los valores reales en los períodos de test, analizando la capacidad para captar tendencias, picos y valles.
- Se destacan las figuras de pronóstico y ajuste (por ejemplo, Figuras 6, 12, 14, 15, 16, 17, 18, 19).

4. Diagnóstico de residuos:

- Se analizaron los residuos y su autocorrelación (Figuras 9, 10, 11).
- La ausencia de autocorrelación significativa en los residuos indica que el modelo ha captado correctamente la estructura temporal.

5. Comparación entre modelos:

- Prophet y SARIMA lograron captar mejor la estacionalidad anual y semanal.
- LSTM captó bien la tendencia, aunque suavizó picos extremos.
- Los modelos ARIMA/SARIMA sirvieron de baseline sólido y requieren ajuste manual.

5. Conclusiones

1. Pregunta de investigación:

- *¿En qué medida es posible predecir con precisión las ventas diarias de café utilizando únicamente información histórica, y cuál de los modelos propuestos (ARIMA, LSTM, Prophet, LightGBM) resulta más eficaz para anticipar la dinámica de la serie temporal?*

2. Sobre el fenómeno estudiado:

- Las ventas diarias de café presentan tendencia creciente y una fuerte estacionalidad, con picos pronunciados en ciertos meses del año (especialmente octubre-diciembre).
- Se identifican outliers y fluctuaciones diarias asociadas a ciclos de consumo y factores externos no reflejados en el dataset.

3. Sobre los modelos utilizados:

- Prophet fue el modelo más eficaz para captar patrones de estacionalidad y tendencia, con una interpretación sencilla y resultados consistentes.
- SARIMA/ARIMA funcionaron como baseline sólidos, especialmente cuando se ajustaron correctamente los parámetros según el análisis de autocorrelación.
- LSTM mostró potencial para patrones no lineales y relaciones de largo plazo, pero suavizó los extremos y requiere mayor volumen de datos para destacar plenamente.
- Los modelos de suavizamiento aportaron claridad sobre las tendencias, pero no predicen bien eventos abruptos o outliers.

4. Lecciones aprendidas:

- La calidad y el preprocesamiento de los datos (limpieza, agregación diaria, manejo de fechas) son críticos para la obtención de buenos resultados.
- Las métricas cuantitativas deben ser complementadas con diagnóstico visual y análisis de residuos.
- La falta de variables exógenas limita la explicación de ciertos picos o caídas, lo que indica la necesidad de enriquecer el dataset en trabajos futuros.
- Es recomendable ajustar y combinar modelos periódicamente, adaptando la estrategia a la evolución del negocio y del mercado.

5. Respuesta a la pregunta de investigación y recomendaciones:

- Se concluye que es posible predecir con precisión razonable las ventas diarias de café utilizando únicamente la información histórica, siempre que la serie presente patrones claros de estacionalidad y tendencia.
- Prophet y SARIMA resultaron los modelos más eficaces para este contexto, gracias a su capacidad para captar tanto tendencia como ciclos estacionales.
- La incorporación de variables adicionales (promociones, clima, feriados, etc.) podría mejorar significativamente la capacidad predictiva de los modelos.
- **Para futuras investigaciones se recomienda:** expandir el horizonte temporal, incorporar variables externas relevantes y explorar combinaciones híbridas de modelos para aumentar la precisión y robustez de las predicciones.