



Análisis exploratorio y predictivo de la demanda de café a partir de series temporales

Autores:

Ignacio Tomás de Pedro Mermier - Luciano Adassus

Índice

1. Planteamiento de pregunta de investigación	3
2. Descripción de los datos	3
2.1 Análisis exploratorio de datos - General	4
2.2 Análisis de Datos - Series de Tiempo	6
3. Descripción de los modelos	9
4. Pruebas sobre los modelos	14
5. Conclusiones	15

1. Planteamiento de pregunta de investigación

El objetivo principal de este análisis es responder a la siguiente pregunta:

¿En qué medida es posible predecir con precisión las ventas diarias de café utilizando únicamente información histórica, y cuál de los modelos propuestos (ARIMA, SARIMA, Prophet y Holt-Winters) resulta más eficaz para anticipar la dinámica de la serie temporal?

Contexto y motivación:

La predicción de ventas en el sector de retail es una necesidad crítica para la planificación operativa, logística y financiera. En particular, las ventas de café pueden verse afectadas por patrones estacionales, tendencias a largo plazo, eventos puntuales (promociones, feriados) y posibles factores externos como el clima o cambios en el comportamiento del consumidor. Poder anticipar el volumen de ventas diarias permite ajustar la producción, optimizar inventarios y diseñar estrategias de marketing más efectivas.

Alcance:

El análisis se limita a las ventas diarias históricas de café contenidas en el dataset seleccionado [Coffee Sales Dataset en Kaggle](#)

No se incorporan variables exógenas (clima, promociones, etc.), lo que establece un “piso” de performance basado sólo en patrones temporales propios de la serie.

El foco está tanto en la precisión de las predicciones como en la interpretabilidad y facilidad de uso de cada enfoque.

2. Descripción de los datos

Atributo	Tipo de Datos	Descripción
date	date	Fecha de la transacción (año-mes-día), útil para análisis agregados diarios.
datetime	datetime	Fecha y hora de la transacción de venta. Permite agrupar y ordenar temporalmente.
cash-type	string	Medio de pago utilizado (por ejemplo: ‘card’ para tarjeta, ‘cash’ para efectivo).
card	string	Identificador anónimo del medio de pago o del cliente (por ejemplo, tokenizado para preservar privacidad).
money	float	Importe total vendido en cada transacción, expresado en la moneda local.
coffe-name	string	Nombre comercial del tipo de café vendido (ejemplo: “Latte”, “Espresso”).

Utilidad y observaciones sobre cada atributo:

- **date:** es fundamental para la agregación diaria de ventas, que es la base de este análisis de series de tiempo.
- **datetime:** permite análisis a nivel de hora/minuto y, a futuro, puede usarse para estudiar patrones intradía, horarios pico, o planificar turnos de personal.
- **cash-type:** Indica si la compra fue realizada con tarjeta o efectivo. Si se dispone del dato, podría usarse para analizar tendencias en medios de pago, evaluar el impacto de promociones específicas para un método o detectar patrones asociados a cierto perfil de cliente.
- **card:** Es un identificador único anonimizado, útil para analizar la recurrencia de clientes, detectar hábitos de consumo, o incluso segmentar por frecuencia de compra.
- **money:** Es la variable objetivo para el análisis predictivo. Sumarizando por fecha, permite construir la serie diaria de ventas.
- **coffe-name:** Permite segmentar ventas por tipo de producto. En este análisis, la suma total de money por día es el foco, pero con este atributo es posible profundizar a nivel de preferencias de consumo, lanzamientos exitosos, o estacionalidad por producto.

Ventajas del esquema:

- Permite análisis univariados (ventas diarias totales) y multivariados (por tipo de producto, medio de pago, cliente).
- Facilita el cruce de información por fecha, tipo de producto o comportamiento de compra, habilitando estudios de patrones y segmentación avanzada.

Limitaciones:

- No se dispone de variables externas (promociones, clima, feriados), lo que acota la explicación de picos o caídas atípicas.
- El identificador de cliente está anonimizado; útil para estudios de recurrencia, pero limita la personalización.

2.1. Análisis exploratorio de datos - General

En esta sección se presentan tres análisis iniciales que permiten comprender el comportamiento de las ventas de café en distintos horarios del día.




Figura 1. Distribución de las ventas de café a lo largo del día.

Venta de café a lo largo del día Para todos los casos, se observa una media entre los 25 y 35 dólares. Sin embargo, para los horarios entre las 19:00 y las 21:00 horas, la media incrementa levemente y la dispersión de los datos disminuye significativamente con respecto a los demás horarios. Esto supone que en esos horarios se venden, sobre todo, productos más caros.




Figura 2. Ventas totales de café por hora del día.

Venta total de café por hora del día Se observa un pico a las 10:00 horas y otro pico a las 16:00 horas, lo que supone horarios de desayuno y merienda. Luego, los valores más bajos corresponden con el momento más temprano de la mañana y el último horario de la noche.




Figura 3. Facturación horaria discriminada por tipo de café o producto.

Venta por producto por hora del día Utilizando la discriminación de la facturación horaria por tipo de café o producto, se pueden explicar de forma más detallada los picos de consumo anteriores: para el pico de consumo de la mañana, el mismo se explica por los picos de venta del *Latte* y del *Americano con Leche*; mientras que el pico de consumo de la tarde se explica sobre todo por el consumo de *Latte* y un aumento relativo de consumo de *Cocoa* (leche chocolatada).

2.2. Análisis de Datos - Series de Tiempo

Para este caso, verificamos que no existen valores nulos en los campos `datetime` y `money`, lo cual descarta la necesidad de una imputación de datos. Tampoco se detectaron valores atípicos significativos utilizando un análisis de boxplots, lo que sugiere que no hay registros con errores evidentes de facturación ni inconsistencias de carga.

Por lo tanto, no fue necesario realizar un proceso de limpieza exhaustivo, y se pudo proceder directamente al análisis y agregación de las ventas por fecha.




Figura 4. Ventas o facturación a lo largo del periodo marzo 2024 - marzo 2025.

Se observa una serie temporal con variaciones pronunciadas, donde se destacan patrones de tendencia y picos recurrentes, sugiriendo la presencia de estacionalidad y posibles eventos atípicos.

Antes de aplicar modelos de pronóstico, es fundamental comprender la estructura interna de la serie temporal. Una manera de lograrlo es mediante la descomposición de la serie en sus componentes fundamentales: **tendencia** y **ciclo**.

Para este propósito, se empleó el **filtro de Hodrick-Prescott (HP)**, una herramienta ampliamente utilizada en el análisis de series de tiempo. Este filtro permite separar la serie original en dos componentes:

- **Tendencia (trend)**: representa la evolución a largo plazo de la serie, suavizando las fluctuaciones de corto plazo.
- **Ciclo (cycle)**: captura las variaciones transitorias alrededor de la tendencia, como efectos estacionales o choques temporales.

La descomposición mediante el filtro HP resulta particularmente útil cuando se desea analizar la dirección general de una serie sin verse influenciado por su volatilidad de corto plazo.

A continuación, se presenta la aplicación del filtro HP sobre la serie de ventas agregadas por fecha, con el objetivo de visualizar su comportamiento estructural y facilitar la identificación de patrones estacionales o puntos de inflexión en la tendencia.




Figura 5. Descomposición de la serie temporal mediante el filtro de Hodrick-Prescott.

A partir de la descomposición realizada mediante el filtro de Hodrick-Prescott, se puede observar con claridad la evolución de la componente de tendencia a lo largo del tiempo.

En particular, se identifican los siguientes puntos relevantes:

- Un **máximo global** a finales del mes de **octubre** y comienzos del mes de **noviembre**, lo cual podría estar relacionado con el inicio del invierno en el hemisferio norte.
- **Máximos locales** en los meses de **febrero, junio y agosto**, que podrían estar asociados a picos temporales de actividad o eventos específicos del calendario escolar. Esto sugiere que la máquina expendedora podría encontrarse en un entorno educativo, como por ejemplo, una universidad.

Con el objetivo de analizar en mayor detalle la presencia de patrones estacionales de corto plazo, se realizó un enfoque exploratorio centrado exclusivamente en el mes de **octubre de 2024**. Este recorte temporal permitió observar más claramente la variación intra-semanal de las ventas.

Al graficar la serie durante este período y aplicar técnicas de suavizado, se identificó una **tendencia semanal** bien definida. En particular, se observan **mínimos de ventas en los días sábado**, lo que sugiere un comportamiento estacional asociado a la dinámica semanal del negocio.

Como ejemplo representativo, el **sábado 5 de octubre de 2024** presentó uno de los niveles más bajos de ventas del mes, lo cual refuerza la hipótesis de que los sábados constituyen sistemáticamente puntos de caída en la actividad comercial.

Este tipo de estacionalidad semanal será especialmente relevante al momento de seleccionar modelos que incorporen componentes estacionales, como SARIMA o Prophet.




Figura 6. Ventas diarias durante el mes de octubre de 2024. Se observa un patrón de caída sistemática los días sábado.

Con el objetivo de validar cuantitativamente la presencia de estacionalidad semanal observada previamente de forma visual, se aplicó una descomposición aditiva utilizando una frecuencia de **7 días**.

El resultado confirmó de manera clara una **estacionalidad semanal pronunciada**, con patrones sistemáticos que se repiten cada siete días, lo cual concuerda con el análisis exploratorio realizado previamente.

Además, el **componente residual** mostró una variabilidad acotada, con valores contenidos en el rango aproximado de ± 250 , mientras que la serie original oscila entre **0 y 750**. Este resultado indica que una parte considerable de la variabilidad de la serie puede explicarse adecuadamente mediante los componentes de tendencia y estacionalidad, lo que valida la utilidad de esta descomposición y sugiere que el modelo capta bien las dinámicas principales de la serie.




Figura 7. Descomposición aditiva de la serie temporal con frecuencia semanal (7 días). Se visualizan las componentes de tendencia, estacionalidad y residuo.

Antes de aplicar modelos de series de tiempo como ARIMA o SARIMA, es esencial evaluar si la serie temporal bajo estudio presenta **estacionaridad**, es decir, si sus propiedades estadísticas (media, varianza y autocorrelación) se mantienen constantes a lo largo del tiempo.

Para ello, se utilizó la **prueba de Dickey-Fuller aumentada (ADF)**, una herramienta estadística que permite contrastar la presencia de una raíz unitaria en la serie, lo cual indicaría no estacionaridad.

Se realizaron dos evaluaciones:

- **Serie original (sin diferenciación):** el resultado de la prueba ADF arrojó un **p-valor de 0,022**, lo que permite **rechazar la hipótesis nula de no estacionaridad** con un nivel de confianza del 95 %. Esto implica que la serie es estacionaria incluso sin necesidad de diferenciación.
- **Serie diferenciada una vez:** en este caso, el p-valor fue prácticamente **negligible** (cercano a cero), lo que confirma de forma aún más contundente la **estacionaridad** de la serie tras la transformación.

Estos resultados validan la adecuación de modelos que requieren estacionaridad, y permiten explorar variantes tanto con como sin diferenciación para optimizar la predicción.

3. Descripción de los modelos

El análisis se basó en una comparación de distintas familias de modelos para prever la evolución de las ventas diarias de café, considerando la serie histórica y los patrones visualizados en la exploración inicial.

1. Modelos clásicos de series temporales: ARIMA y SARIMA:

1.1. Justificación del modelo:

- Los modelos ARIMA (AutoRegressive Integrated Moving Average) y su extensión SARIMA (que incorpora estacionalidad) son ampliamente utilizados en predicción de series temporales, especialmente cuando se detectan componentes de tendencia y estacionalidad. Su fortaleza radica en la interpretación de componentes lineales y la descomposición en partes autoregresivas, integradas y de promedio móvil.

1.2. Preparación de datos:

- La serie diaria de ventas se transforma para asegurar la estacionaridad (eliminando tendencia y estacionalidad mediante diferenciación, si es necesario).
- Se analizan los gráficos de autocorrelación (ACF) y autocorrelación parcial (PACF) para definir los parámetros óptimos del modelo (p, d, q, y sus equivalentes estacionales).

1.3. Aportes del modelo:

- Muy bueno para series estacionarias y lineales.
- Su diagnóstico y tuning es transparente y basado en métodos estadísticos robustos.

- Como baseline, permite comparar contra modelos más complejos.

Ya que garantizamos la estacionaridad de nuestra serie tanto en su forma original como en su forma diferenciada una vez, procederemos a evaluar el desempeño de modelos **ARIMA** utilizando dos configuraciones distintas: una con $d = 0$ y otra con $d = 1$.

La selección de los parámetros p y q para cada configuración se realizó a partir del análisis gráfico de la **Función de Autocorrelación (ACF)** y la **Función de Autocorrelación Parcial (PACF)**:

- Para $d = 0$, se identificaron valores de $p = 5$ y $q = 18$.
- Para $d = 1$, se seleccionaron $p = 7$ y $q = 2$.

A continuación, se presentan los gráficos de ACF y PACF correspondientes a cada configuración, los cuales respaldan la elección de los parámetros para los modelos propuestos.




Figura 8. ACF y PACF para la serie original ($d = 0$)




Figura 9. ACF y PACF para la serie diferenciada ($d = 1$)

Posteriormente, se entrenaron ambos modelos ARIMA utilizando el **90 % inicial** de la serie temporal como conjunto de entrenamiento, reservando el **10 % restante** para evaluar su capacidad predictiva.

Esta división temporal respeta la estructura secuencial inherente a las series de tiempo y permite validar la habilidad del modelo para extrapolar patrones más allá del rango observado.

En la siguiente figura se presentan las predicciones generadas por ambos modelos (ARIMA con $d = 0$ y ARIMA con $d = 1$) comparadas con los valores reales del conjunto de prueba:




Figura 10. Comparación de predicciones de los modelos ARIMA ($d = 0$ y $d = 1$) con el conjunto de prueba

Como puede observarse, ambos modelos capturan adecuadamente la tendencia general de las ventas. Sin embargo, se analizarán métricas de error más adelante para determinar cuál de los dos logra un mejor ajuste cuantitativo sobre los datos de validación.

Adicionalmente, se implementó un modelo **SARIMA** con el objetivo de capturar explícitamente la **estacionalidad semanal** detectada previamente en la serie temporal. El modelo ajustado tuvo la siguiente parametrización:

$$\text{SARIMA}(1, 1, 1)(1, 1, 1, 7)$$

donde:

- $(p, d, q) = (1, 1, 1)$ corresponden a los parámetros no estacionales del modelo ARIMA,
- $(P, D, Q, s) = (1, 1, 1, 7)$ representan la componente estacional, con $s = 7$ reflejando la estacionalidad semanal de la serie.

Este modelo fue entrenado sobre el mismo **90 % inicial** de la serie que se utilizó en los modelos ARIMA previos, con el objetivo de realizar una comparación directa sobre el **10 % restante**.

A continuación, se presenta la gráfica de predicción generada por el modelo SARIMA, superpuesta con los datos reales del conjunto de prueba:




Figura 11. Predicción del modelo SARIMA(1, 1, 1)(1, 1, 1, 7) comparada con los datos reales

Para automatizar el proceso de selección de parámetros y explorar rápidamente modelos ARIMA adecuados, se implementó un modelo **AutoARIMA**, el cual emplea estrategias

de búsqueda para identificar automáticamente los valores óptimos de p , d , q y, en caso de considerar estacionalidad, también P , D , Q , y s .

En este caso, se configuró el modelo para evaluar una posible **estacionalidad semanal** ($m = 7$), permitiéndole ajustar automáticamente tanto la parte estacional como la no estacional del modelo.

El modelo fue entrenado sobre el mismo **90 % inicial** de la serie de tiempo que se utilizó para los modelos anteriores, y su desempeño fue evaluado sobre el **10 % restante**.

Como resultado, **AutoARIMA seleccionó el modelo ARIMA(0,1,1)(0,1,1)[7]**, lo que implica una doble diferenciación (una regular y una estacional) y una estructura simple de medias móviles, tanto para la parte estacional como no estacional.

A continuación, se muestra la predicción obtenida por el modelo AutoARIMA junto con los valores reales correspondientes al conjunto de prueba:




Figura 12. Predicción del modelo AutoARIMA comparada con los datos reales

En este caso particular, se observa que la predicción del modelo presenta una **tendencia creciente en la media** que no refleja de forma precisa el comportamiento real de la serie, el cual se mantiene relativamente estable en el horizonte de predicción. Esto sugiere que, a pesar de la correcta detección de la estacionalidad semanal, la componente de tendencia podría estar sobreajustada en este modelo.

2. Modelo clásico de suavizamiento exponencial: Holt-Winters:

2.1. Justificación del modelo:

- El modelo de Holt-Winters es una técnica clásica de suavizamiento exponencial que permite capturar componentes de nivel, tendencia y estacionalidad en series temporales.
- Es especialmente útil para series con patrones estacionales y tendencias suaves, y ofrece una forma intuitiva y computacionalmente eficiente para la predicción.
- Su simplicidad lo hace adecuado como modelo base para comparar con métodos más complejos.

2.2. Preparación de datos:

- La serie de ventas se utiliza en su forma agregada diaria, sin necesidad de diferenciación.
- Se define una periodicidad estacional acorde a los datos, en este caso semanal (7 días), para capturar patrones recurrentes.

2.3. Aportes del modelo:

- Permite modelar explícitamente nivel, tendencia y estacionalidad.
- Genera pronósticos suavizados que suelen ser robustos ante ruidos o fluctuaciones puntuales.
- Los parámetros del modelo pueden ajustarse fácilmente para mejorar el ajuste y la capacidad predictiva.
- Es una base sólida para la comparación con modelos ARIMA, SARIMA y métodos más avanzados como Prophet.

Se entrenó el modelo Holt-Winters considerando una estacionalidad aditiva con un periodo de 7 días, acorde a la frecuencia semanal identificada previamente en la serie.

El ajuste resultante mostró una buena concordancia entre las predicciones generadas y los datos reales del conjunto de prueba.

Esto evidencia que el modelo es capaz de capturar adecuadamente tanto la tendencia como los patrones estacionales presentes en las ventas diarias de café.




Figura 13. Comparación entre las predicciones del modelo Holt-Winters y los datos reales en el conjunto de prueba.

3. Modelos de tendencia y estacionalidad: Prophet

3.1. Justificación del modelo:

- Prophet, desarrollado por Facebook, está diseñado para captar tendencias y estacionalidades de manera automática, incluso en presencia de outliers o cambios abruptos. Es especialmente útil cuando hay feriados, eventos especiales o patrones estacionales no triviales.

3.2. Preparación de datos:

- Se ajusta la serie en formato compatible con Prophet (dos columnas: fecha y valor).
- El modelo descompone la serie en tendencia, estacionalidad anual, semanal y efectos especiales.
- Permite incorporar feriados (no usados en este caso por falta de datos exógenos).

3.3. Aportes del modelo:

- Ajuste automático y robusto a cambios de patrón.
- Fácil de usar y de interpretar sus componentes.
- Flexible para eventos especiales.

Se entrenó el modelo Prophet considerando una estacionalidad semanal, observándose resultados que ajustan adecuadamente a las ventas diarias.

Este ajuste sugiere que Prophet es capaz de capturar efectivamente las dinámicas temporales del comportamiento de consumo en la máquina expendedora de café.




Figura 14. Comparación entre las predicciones del modelo Prophet y los datos reales en el conjunto de prueba.

Al comparar todos los modelos en términos de las métricas MAE, MSE y RMSE, obtenemos la siguiente tabla comparativa:

Cuadro 1. Comparación de modelos según MAE, MSE y RMSE

Modelo	MAE	MSE	RMSE
Holt-Winters	143.18	26691.32	163.37
ARIMA (5,1,18)	182.11	45565.09	213.46
ARIMA (0,1)	180.12	43702.21	209.05
SARIMA	194.21	53699.72	231.73
AutoARIMA	261.96	95382.20	308.84
Prophet	130.26	25651.02	160.16

Al comparar los primeros 5 modelos términos de las métricas de complejidad AIC y BIC, las cuales penalizan la complejidad del modelo, obtenemos la siguiente tabla comparativa:

Cuadro 2. Comparación de modelos según AIC y BIC

Modelo	AIC	BIC
Holt-Winters	3383.39	3425.57
ARIMA (5,18)	4353.71	4449.58
ARIMA (0,1)	4329.40	4363.88
SARIMA	4646.96	4666.45
AutoARIMA	4347.26	4377.75

4. Pruebas sobre los modelos

1. División de datos (train-test):

- Se reservó una parte de la serie temporal para testear los modelos fuera del período de entrenamiento, evaluando así la capacidad de generalización y evitando el sobreajuste.

2. Métricas de evaluación:

- Se emplearon métricas estándar para comparar el desempeño de los modelos:
 - MAE (Mean Absolute Error)
 - MSE (Mean Squared Error)
 - RMSE (Root Mean Squared Error)
- Se consideró como mejor modelo aquel que presenta menor MAE/MSE/RMSE .

3. Métricas de comparación de complejidad:

- Se emplearon métricas estándar para comparar la complejidad de los modelos:
 - AIC (Akaike Information Criteria)
 - BIC (Beyseian Information Criteria)
- Se consideró como mejor modelo aquel que presenta menor AIC/BIC .

4. Validación visual:

- Se graficaron los valores predichos por cada modelo contra los valores reales en los períodos de test, analizando la capacidad para captar tendencias, picos y valles.
- Se destacan las figuras de pronóstico y ajuste de los modelos Holter-Winter, SARIMA y Prophet.

5. Conclusiones

1. Pregunta de investigación:

- *¿En qué medida es posible predecir con precisión las ventas diarias de café utilizando únicamente información histórica, y cuál de los modelos propuestos (ARIMA, SARIMA, Prophet y Holt-Winters) resulta más eficaz para anticipar la dinámica de la serie temporal?*

2. Sobre el fenómeno estudiado:

- Las ventas diarias de café presentan tendencia creciente y una fuerte estacionalidad, con picos pronunciados en ciertos meses del año (especialmente octubre-diciembre).
- Se identifican outliers y fluctuaciones diarias asociadas a ciclos de consumo y factores externos no reflejados en el dataset.

3. Sobre los modelos utilizados:

- Prophet fue el modelo más eficaz para captar patrones de estacionalidad y tendencia, con una interpretación sencilla y resultados consistentes.
- SARIMA/ARIMA funcionaron como baseline sólidos, especialmente cuando se ajustaron correctamente los parámetros según el análisis de autocorrelación.
- Los modelos de suavizamiento aportaron claridad sobre las tendencias, pero no predicen bien eventos abruptos.

4. Lecciones aprendidas:

- La calidad y el preprocesamiento de los datos (limpieza, agregación diaria, manejo de fechas) son críticos para la obtención de buenos resultados.

- Las métricas cuantitativas deben ser complementadas con diagnóstico visual y análisis de residuos.
- La falta de variables exógenas limita la explicación de ciertos picos o caídas, lo que indica la necesidad de enriquecer el dataset en trabajos futuros.
- Es recomendable ajustar y combinar modelos periódicamente, adaptando la estrategia a la evolución del negocio y del mercado.

5. Respuesta a la pregunta de investigación y recomendaciones:

- Se concluye que es posible predecir con precisión razonable las ventas diarias de café utilizando únicamente la información histórica, siempre que la serie presente patrones claros de estacionalidad y tendencia.
- El modelo Holt-Winters tiene, por amplio margen, los valores más bajos tanto de AIC como de BIC, lo cual indica que logra un excelente balance entre precisión y simplicidad. Esto refuerza su buen desempeño ya observado con las métricas de error.
- AutoARIMA fue el modelo con peor desempeño. Esto podría deberse a que el enfoque automático no encontró una configuración óptima para los patrones específicos de esta serie, o bien que el modelo sobreajustó sin capturar adecuadamente la dinámica real.
- Prophet y Holt-Winters resultaron los modelos más eficaces para este contexto, gracias a su capacidad para captar tanto tendencia como ciclos estacionales.
- La incorporación de variables adicionales (promociones, clima, feriados, etc.) podría mejorar significativamente la capacidad predictiva de los modelos.
- **Para futuras investigaciones se recomienda:** expandir el horizonte temporal, incorporar variables externas relevantes y explorar combinaciones híbridas de modelos para aumentar la precisión y robustez de las predicciones.